Revisión

Trabajo de Maestría en Ciencia de Datos

Estimación Municipal Sobre la Tasa de Desempleo en el Cauca y Valle del Cauca: Estimación de Área Pequeña usando Modelos Mixtos y Componentes Espaciales

Documento de orientación para revisión

1. Síntesis revisada

Como modelo de referencia, la formulación general del Fay–Herriot es pertinente. Es correcto distinguir el modelo de muestreo del modelo de enlace, estimar la varianza del efecto aleatorio mediante REML, estimar los coeficientes mediante GLS, construir el EBLUP con su factor de contracción y utilizar ML para comparar AIC entre especificaciones con diferentes efectos fijos.

También es correcto que, bajo el Fay–Herriot clásico con efectos de área independientes, un municipio sin estimación directa no tenga componente directo y su predictor quede reducido al componente sintético $x_d^\top \widehat{\beta}$. Esta característica no debe criticarse como ausencia de espacialidad: corresponde precisamente al benchmark no espacial que posteriormente deberá compararse con el predictor del modelo espacial.

Sin embargo, antes de construir la extensión espacial deben resolverse aspectos sustantivos del benchmark:

1. correspondencia geográfica entre los dominios GEIH y las covariables de TerriData;
2. precisión y período de referencia de las estimaciones directas;
3. estimación de las varianzas de muestreo;
4. coherencia de la selección de covariables;
5. validación fuera del conjunto utilizado para seleccionar y ajustar el modelo;
6. elevada extrapolación desde capitales o áreas urbanas hacia municipios;
7. interpretación de los coeficientes y de la incertidumbre.

2. Reclasificación de observaciones de la evaluación anterior

Observación	Clasificación anterior	Clasificación corregida con la aclaración del estado del proyecto
No se ha ajustado todavía el modelo espacial	Se trató como contradicción crítica.	*No es error*. Es una etapa pendiente del trabajo. Debe quedar explícito que el modelo actual es el benchmark no espacial.
El objetivo específico 1 aún no compara modelos espaciales	Se interpretó como objetivo no cumplido.	*Pendiente de evaluación*. En esta versión solo puede evaluarse si el benchmark está bien construido. M1–M5 son variantes internas del benchmark, no la comparación final requerida por el objetivo.
El objetivo específico 3 no presenta patrones espaciales	Se interpretó como incumplimiento.	*Pendiente por estado de avance*. No debe exigirse una conclusión espacial antes de ajustar y diagnosticar el modelo espacial.
No se reporta todavía la matriz espacial W	Se trató como ausencia metodológica.	*Pendiente de la etapa espacial*. No obstante, conviene definir desde ahora cuál será la unidad espacial y cómo se construirá W, porque la definición de los dominios del benchmark condiciona esa matriz.
El predictor de municipios sin encuesta es $x_d^\top \widehat{\beta}$	Podía interpretarse como falta del componente espacial.	*Correcto para el Fay–Herriot clásico*. En el futuro modelo espacial el predictor para áreas no observadas deberá modificarse si la estructura espacial permite predecir el efecto aleatorio de áreas sin muestra.
La discusión y las conclusiones están incompletas	Se señaló como no reportado.	*Esperable en esta etapa*. Deben escribirse después de completar la comparación espacial y la validación final.

3. Matriz revisada por objetivo específico

Objetivo	Etapa actual	Evidencia disponible	Estado actual	Qué falta
Evaluar el desempeño de distintos modelos SAE basados en modelos mixtos con componentes espaciales.	Construcción del benchmark Fay–Herriot clásico.	Se comparan M1–M5, que son especificaciones de efectos fijos del mismo modelo clásico.	*En desarrollo.* No debe juzgarse todavía como incumplido.	Corregir y congelar un benchmark defendible; posteriormente ajustar el modelo espacial y compararlo bajo la misma tarea y los mismos dominios.
Determinar las variables explicativas con mayor incidencia.	Existe selección preliminar dentro del benchmark.	M2 conserva cobertura secundaria, VA primario e IPM; los coeficientes son inestables y ninguno alcanza 5 % de significancia.	*Parcial y preliminar.*	Revisar selección, estabilidad e interpretación; volver a contrastar los coeficientes después de incorporar la estructura espacial.
Analizar distribución y patrones espaciales del desempleo.	Todavía no se ha desarrollado la etapa espacial.	Se dispone de distribución territorial y predicciones del benchmark.	*No evaluable todavía como objetivo final.*	Ajustar el modelo espacial, definir W, analizar dependencia y comparar residuos y predicciones con el benchmark.

4. Aspectos del modelo base que están correctamente planteados

4.1. Formulación del Fay–Herriot clásico

La formulación general es pertinente para un modelo a nivel de área:

$$\widehat{\theta}_d = \theta_d + e_d, \qquad e_d \sim N(0, \psi_d),$$

$$\theta_d = x_d^\top \beta + u_d, \qquad u_d \overset{iid}{\sim} N(0, A).$$

Es correcta la interpretación del factor de contracción:

$$\gamma_d = \frac{A}{A + \psi_d},$$

y del EBLUP como combinación de estimación directa y predictor sintético.

4.2. Estimación de los parámetros

Es metodológicamente adecuado:

- estimar A mediante REML para obtener las predicciones;
- estimar β mediante GLS condicionado a $\widehat{A}$;
- utilizar ML para el AIC cuando se comparan modelos con diferentes efectos fijos;
- calcular el EBLUP y una aproximación de su MSE.

4.3. Predicción de áreas sin muestra en el benchmark

Para el modelo clásico independiente, es correcto que en un área sin estimación directa el predictor sea:

$$\widehat{\theta}_d^{SIN} = x_d^\top \widehat{\beta}.$$

Por tanto, este elemento debe mantenerse como benchmark. Cuando se construya el modelo espacial, debe derivarse el predictor correspondiente a esa nueva estructura; no se debe copiar automáticamente la fórmula del modelo clásico.

4.4. ML para AIC y REML para estimación

La separación implementada entre REML para estimación y ML para comparación de modelos con diferentes efectos fijos es una buena decisión metodológica y debe mantenerse.

4.5. Reconocimiento de la extrapolación

Es una fortaleza que el documento marque los municipios que quedan fuera del soporte de las áreas de ajuste. Esa información será especialmente útil cuando se compare el benchmark con el modelo espacial.

5. Problemas del benchmark que deben corregirse antes del modelo espacial

5.1. G7-B1. Correspondencia geográfica entre respuesta y covariables

Estado: Error documental demostrado y auditoría de implementación indispensable.

Gravedad: Crítica para el benchmark.

Ubicación: Sección 5.4.1, pp. 39–41; Sección 5.9, p. 55.

El documento indica que la GEIH utiliza un código de área de dos dígitos y que se construye una tabla para asociarlo con el DIVIPOLA de la ciudad capital.

Este punto debe corregirse antes de continuar. La documentación oficial de la GEIH 2018 identifica varios códigos `AREA` como áreas metropolitanas: por ejemplo, Cali–Yumbo, Medellín–Valle de Aburrá, Barranquilla–Soledad, Pereira AM, Bucaramanga AM y Cúcuta AM. Véase:

`https://microdatos.dane.gov.co/index.php/catalog/547/variable/F258/V13409?name=AREA`

La ficha metodológica de la GEIH también distingue explícitamente las ciudades y sus áreas metropolitanas:

`https://www.dane.gov.co/files/investigaciones/fichas/empleo/ficha_metodologica_GEIH-01_V10.pdf`

Por tanto, si la respuesta de un dominio corresponde, por ejemplo, a Cali–Yumbo, no es correcto emparejarla únicamente con las covariables municipales de Cali.

En Fay–Herriot se requiere que:

$$\widehat{\theta}_d, \qquad \psi_d, \qquad x_d$$

correspondan al mismo dominio.

Corrección: construir una tabla de auditoría para los 23 dominios que contenga:

- código GEIH;
- nombre oficial;
- geografía real del dominio;
- municipios que lo integran;
- DIVIPOLA utilizado actualmente;
- regla correcta de construcción de x_d.

Si una respuesta representa un área metropolitana, sus covariables deben construirse para esa misma área. La forma de agregación depende de la naturaleza de cada variable y de su denominador; no debe utilizarse un promedio simple de manera automática.

Este problema es independiente de que el modelo espacial todavía no se haya construido. Si no se corrige, tanto el benchmark como el futuro modelo espacial partirán de dominios incompatibles.

5.2. G7-B2. Diciembre de 2018 debe justificarse mejor como unidad temporal de las estimaciones directas

Estado: Explicación insuficiente; no se considera automáticamente un error.

Gravedad: Mayor.

Ubicación: Secciones 5.5 y 6.5.

La coherencia temporal justifica utilizar 2018, pero no demuestra por sí sola que un único mes sea la mejor base para estimar cada dominio.

La documentación oficial de la GEIH distingue niveles temporales de publicación y precisión; las estimaciones individuales por ciudad o área metropolitana se reportan habitualmente con acumulación trimestral. Véase la ficha metodológica oficial:

`https://www.dane.gov.co/files/investigaciones/fichas/empleo/ficha_metodologica_GEIH-01_V10.pdf`

Esto no demuestra que sea imposible calcular una tasa mensual a partir de microdatos. Sí implica que los estudiantes deben demostrar que la precisión de las tasas mensuales individuales es adecuada.

Corrección: realizar una sensibilidad con:

diciembre 2018, octubre–diciembre 2018, año 2018.

Para cada dominio deben reportarse tamaño muestral, PEA muestral, desempleados muestrales, estimación directa y error estándar. La elección final debe justificarse con evidencia.

5.3. G7-B3. La varianza bootstrap no reproduce el diseño complejo

Estado: Limitación reconocida; interpretación a corregir.

Gravedad: Mayor.

Ubicación: Sección 5.5.1, pp. 44–45; Sección 6.5.

Es correcto reconocer que el bootstrap simple no reproduce estratos ni conglomerados. Lo que debe corregirse es la afirmación de que las varianzas obtenidas necesariamente subestiman la verdadera varianza o constituyen una "cota inferior".

Sin información adicional no puede garantizarse la dirección del sesgo.

Corrección documental: reemplazar esa afirmación por una formulación como:

> Las varianzas bootstrap utilizadas no reproducen completamente el diseño complejo de la GEIH y deben interpretarse como aproximaciones. La dirección y magnitud de su diferencia respecto de la varianza de diseño no se conocen con la información disponible.

Corrección metodológica: revisar si existen variables, réplicas o identificadores que permitan una aproximación más adecuada. Si no existen, realizar análisis de sensibilidad de los resultados frente

a cambios razonables en ψ_d y considerar si una función generalizada de varianza puede aportar estabilidad.

5.4. G7-B4. Debe validarse la construcción de la tasa de desempleo

Estado: Análisis de control faltante.

Gravedad: Mayor.

Antes de utilizar las tasas como entrada del Fay–Herriot, el pipeline debería demostrar que reproduce razonablemente un indicador GEIH oficial en una geografía y período compatibles.

Se recomienda una tabla:

Dominio/período	TD oficial	TD reconstruida	Diferencia
Completar con resultados			

Este control verifica simultáneamente la clasificación de PEA y desempleo, los factores de expansión, las uniones de módulos y la definición geográfica.

5.5. G7-B5. La derivación de PEA debe auditarse

Estado: Explicación insuficiente.

Gravedad: Mayor si la implementación reproduce literalmente la regla descrita.

Ubicación: Sección 5.4.1, p. 40.

Derivar PEA mediante ausencia en el módulo de inactivos puede ser válido únicamente si la persona pertenece previamente a la población en edad de trabajar y si un nulo proviene realmente de la clasificación laboral, no de un fallo de unión.

Debe presentarse una reconciliación por dominio:

$$PET, \qquad PEA, \qquad OC, \qquad DS, \qquad PEI,$$

y verificar:

$$PEA = OC + DS.$$

También debe reportarse el porcentaje de llaves no emparejadas entre módulos.

5.6. G7-B6. Imputar un factor de expansión faltante con cero es conceptualmente incorrecto

Estado: Error en el pipeline; efecto final condicionado a si ocurre en diciembre de 2018.

Gravedad: Menor o mayor según auditoría.

Ubicación: Sección 5.3 y Tabla 6.3.

Un factor faltante no significa peso poblacional cero. Sin embargo, como el análisis actual se concentra en 2018 y el propio documento indica que los factores actualizados están disponibles para esos períodos, no debe afirmarse sin auditoría que este error afectó las tasas finalmente utilizadas.

Corrección: modificar el pipeline y reportar cuántos registros del período analítico fueron afectados. Si fueron cero, documentar que el problema no alteró los resultados actuales.

5.7. G7-B7. Inconsistencia en los umbrales del coeficiente de variación

Estado: Error demostrado.

Gravedad: Mayor documental y en clasificación.

La Tabla 3.1 utiliza 5 % y 20 %, mientras la Sección 5.5.2 presenta 15 % y 30 %. En resultados vuelve a emplearse 5 % y 20 %.

Debe seleccionarse una única regla, justificarla y actualizar todas las clasificaciones. Este problema no depende del modelo espacial y debe corregirse ahora.

5.8. G7-B8. La selección de covariables ignora inicialmente la diferente precisión de las respuestas

Estado: Metodología mejorable.

Gravedad: Mayor.

La respuesta utilizada en la selección es una estimación con error heterocedástico:

$$\widehat{\theta}_d = \theta_d + e_d, \qquad \mathrm{Var}(e_d) = \psi_d.$$

Sin embargo, correlaciones y varias regresiones exploratorias otorgan el mismo peso a todas las áreas.

Dado que ψ_d varía apreciablemente entre dominios, conviene que la selección formal se alinee con la estructura del modelo.

Corrección: conservar Pearson y Spearman como descripción, pero complementar la decisión con modelos univariados o multivariados que incorporen ψ_d, o con desempeño predictivo validado.

5.9. G7-B9. Multiplicidad: el problema reaparece mediante los intervalos de Fisher

Estado: Inconsistencia metodológica.

Gravedad: Mayor.

Se evita reportar valores p de muchas correlaciones por multiplicidad, pero luego se exige que un intervalo de confianza del 95 % excluya cero para declarar una variable elegible.

Ambos procedimientos expresan, aproximadamente, la misma decisión bilateral al 5 %.

Debe adoptarse un criterio coherente: corrección por multiplicidad, control de FDR, estabilidad por remuestreo o selección por validación predictiva.

5.10. G7-B10. El agrupamiento por componentes conexas puede eliminar variables no redundantes entre sí

Estado: Problema matemático demostrado.

Gravedad: Mayor.

La regla conecta dos variables si $|r| \geq 0.80$ y después toma componentes conexas. La alta correlación no es transitiva.

Por tanto, X_1 y X_3 pueden terminar en el mismo grupo aunque:

$$|r(X_1, X_3)| < 0.80,$$

solo porque ambas se conectan con X_2.

El propio resultado muestra grupos de este tipo.

Corrección: utilizar una estrategia que controle la similitud dentro del grupo o resolver la redundancia mediante VIF/modelos candidatos sin convertir artificialmente la correlación en una relación transitiva.

5.11. G7-B11. El orden de los filtros puede eliminar una dimensión por un artefacto del algoritmo

Estado: Problema demostrado.

Gravedad: Mayor.

En algunos grupos la variable representante se elige antes de aplicar un criterio posterior y luego resulta no elegible, mientras otra variable del mismo grupo que fue descartada sí tenía evidencia más favorable.

Corrección: implementar retroceso. Si el representante de un grupo falla en un criterio posterior, evaluar al siguiente candidato antes de eliminar la dimensión completa.

5.12. G7-B12. El signo esperado debe usarse para interpretar, no como filtro automático

Estado: Decisión metodológica que debe revisarse.

Gravedad: Moderada a mayor.

Una asociación de signo contrario a la literatura puede contener información y no debería descartarse automáticamente. El propio documento reconoce posteriormente que un signo inesperado exige interpretación, no necesariamente invalidez.

Además, el signo bivariado y el coeficiente parcial multivariado no tienen por qué coincidir.

Corrección: mantener el signo esperado como diagnóstico de coherencia sustantiva y realizar análisis de sensibilidad con y sin las variables de signo inesperado.

5.13. G7-B13. Inconsistencia Pearson–Spearman y forma funcional

Estado: Incoherencia entre selección y modelo lineal.

Gravedad: Mayor.

Si se decide que Spearman es la asociación interpretable porque Pearson está condicionado por observaciones extremas, debe justificarse por qué posteriormente la variable entra sin transformación a un modelo lineal.

En particular, no es coherente utilizar Spearman para ordenar una variable y el intervalo de Pearson para decidir su elegibilidad sin una justificación adicional.

Corrección: examinar forma funcional, gráficos parciales y transformaciones antes de fijar el predictor lineal.

5.14. G7-B14. El IPM es útil como auxiliar, pero su interpretación no debe ser causal

Estado: Interpretación a corregir.

Gravedad: Mayor para el objetivo 2; no invalida el benchmark predictivo.

El IPM puede ser una covariable auxiliar válida si está disponible para todos los dominios. Sin embargo, contiene dimensiones relacionadas con condiciones laborales, por lo que no debe interpretarse automáticamente como causa externa del desempleo.

Debe distinguirse:

$$\text{utilidad predictiva} \neq \text{asociación} \neq \text{incidencia causal.}$$

Este punto será aún más importante al comparar los coeficientes del modelo clásico y el espacial.

5.15. G7-B15. M1–M5 son variantes del benchmark, no los modelos finales del objetivo 1

Estado: Corrección conceptual/documental.

Gravedad: Moderada.

Ubicación: Secciones 5.9–5.12.

La comparación M1–M5 es útil para seleccionar la parte fija del benchmark. Debe conservarse si se justifica.

Lo que debe corregirse es la trazabilidad que presenta esas variantes como si con ellas se atendiera ya el objetivo de comparar distintos modelos SAE con componente espacial.

En la versión actual, M1–M5 deben denominarse:

especificaciones candidatas del modelo base Fay–Herriot clásico.

La comparación correspondiente al objetivo 1 ocurrirá después entre el benchmark seleccionado y las especificaciones espaciales.

5.16. G7-B16. M2 es una elección razonable por la regla aplicada, pero no es claramente superior

Estado: Interpretación a moderar.

Gravedad: Moderada.

M1, M2, M3 y M5 presentan diferencias de AIC pequeñas. Por ello M2 puede elegirse como benchmark parsimonioso, pero no debe afirmarse que los datos demuestran una superioridad contundente.

Con $D = 23$ resulta recomendable calcular también AICc.

Usando los números de parámetros reportados, la corrección por tamaño pequeño mantiene a M2 entre los mejores modelos, pero la diferencia con M5 continúa siendo muy pequeña.

La redacción recomendada es:

> M2 fue seleccionado, entre varias especificaciones con soporte similar, mediante la regla de parsimonia predefinida y se utilizará como benchmark para la comparación espacial.

5.17. G7-B17. La significancia de los coeficientes no debe utilizarse como demostración fuerte

Estado: Inferencia posterior a selección.

Gravedad: Mayor para el objetivo 2.

Las mismas 23 áreas se utilizan para filtrar, seleccionar, comparar especificaciones y posteriormente calcular valores p de los coeficientes.

Por tanto, esos valores p no tienen la misma interpretación que tendrían en un modelo definido completamente a priori.

Además, en M2 ninguno de los tres coeficientes alcanza $p < 0.05$.

La conclusión actual debe limitarse a asociaciones preliminares del benchmark. El objetivo 2 debe reconsiderarse después de incorporar el componente espacial y estudiar la estabilidad de los coeficientes.

5.18. G7-B18. La sensibilidad a dominios individuales es importante

Estado: Resultado relevante que debe ampliarse.

Gravedad: Mayor.

Aunque ningún dominio supera el umbral de Cook en M2, al retirar Neiva algunos coeficientes cambian aproximadamente 37 % y 47 %.

Esto indica que el benchmark tiene sensibilidad sustantiva con solo 23 áreas.

Corrección: realizar leave-one-area-out de los coeficientes y reportar para cada β_j:

$$\min_d \widehat{\beta}_j^{(-d)}, \qquad \max_d \widehat{\beta}_j^{(-d)},$$

cambio relativo máximo, cambios de signo y cambios importantes en predicciones.

5.19. G7-B19. Falta validación predictiva del benchmark

Estado: Análisis faltante.

Gravedad: Mayor.

El benchmark será utilizado después para evaluar si el componente espacial mejora el desempeño. Por ello debe tener una evaluación predictiva anterior a la comparación espacial.

Se recomienda leave-one-area-out:

1. retirar el área d;
2. ajustar el benchmark con las demás;
3. predecir el área retirada como si no tuviera estimación directa;
4. comparar la predicción con la estimación directa observada.

Debe recordarse que la estimación directa usada como referencia tiene error de muestreo. Por ello no basta con reportar RMSE bruto. Conviene complementar con errores estandarizados que incorporen ψ_d y explicar que se valida contra una referencia ruidosa, no contra el verdadero θ_d.

Idealmente deben presentarse dos ejercicios:

- LOAO con las covariables de M2 fijadas;
- LOAO del procedimiento completo, repitiendo dentro de cada iteración los pasos de selección que dependen de la respuesta.

5.20. G7-B20. La extrapolación masiva sigue siendo un problema, aunque el modelo espacial esté pendiente

Estado: Problema demostrado.

Gravedad: Crítica para la interpretación de predicciones municipales.

El benchmark identifica 76 de 82 municipios como extrapolaciones y 72 estimaciones sintéticas superan el máximo de las estimaciones directas utilizadas para ajustar.

Este resultado es útil como diagnóstico del benchmark, pero también muestra una dificultad fundamental de transportabilidad.

El modelo espacial puede reducir parte de la incertidumbre o capturar estructura geográfica, pero *no debe suponerse que resolverá automáticamente el problema de falta de soporte de las covariables.*

Antes de la comparación final conviene documentar:

- rangos de cada covariable en entrenamiento y municipios objetivo;
- distancia multivariada al soporte de entrenamiento;
- variables responsables de la extrapolación;
- sensibilidad de las predicciones.

5.21. G7-B21. Las categorías de confiabilidad son condicionales al benchmark

Estado: Interpretación a precisar.

Gravedad: Mayor.

El CV de la predicción sintética cuantifica incertidumbre bajo el modelo supuesto. No incluye completamente incertidumbre por selección, mala especificación o cambio de distribución entre capitales y municipios.

Por tanto, para municipios extrapolados se recomienda informar:

> CV condicional al modelo base + estado de extrapolación.

No interpretar "aceptable" como validación empírica de la tasa municipal.

5.22. G7-B22. Media residual y Shapiro–Wilk deben interpretarse con prudencia

Estado: Interpretación a moderar.

Gravedad: Menor a moderada.

Que los residuos estén aproximadamente centrados no demuestra por sí solo ausencia de sesgo del predictor. Asimismo, no rechazar normalidad con 23 residuos no demuestra normalidad separada de los errores de muestreo y los efectos aleatorios.

La redacción correcta es:

> Los diagnósticos no muestran evidencia fuerte contra la aproximación normal en el benchmark, dentro de la limitada potencia disponible con 23 áreas.

6. Qué debe hacerse ahora, antes de construir el modelo espacial

El orden recomendado de trabajo es:

1. resolver definitivamente la geografía de los 23 dominios;

2. validar la reconstrucción de la tasa de desempleo;
3. revisar período y tamaños muestrales;
4. revisar ψ_d y la estrategia bootstrap;
5. corregir los umbrales de CV;
6. revisar la selección de covariables y congelar una especificación base defendible;
7. calcular AICc como complemento;
8. realizar sensibilidad leave-one-area-out;
9. realizar validación predictiva leave-one-area-out;
10. caracterizar con detalle la extrapolación hacia los municipios objetivo;
11. documentar el benchmark definitivo;
12. solo entonces construir el componente espacial.

7. Cómo debe prepararse el benchmark para una comparación justa con el modelo espacial

Cuando se construya el modelo espacial, la comparación debe aislar el aporte de la estructura espacial.

La comparación principal debería mantener, en lo posible:

misma respuesta, mismos ψ_d, mismos dominios, mismas covariables fijas.

De esta manera puede compararse:

FH clásico vs. FH espacial.

Si simultáneamente se cambian covariables y estructura espacial, una mejora no podrá atribuirse exclusivamente al componente espacial.

Puede existir, adicionalmente, una segunda comparación entre el mejor modelo clásico y el mejor modelo espacial, pero esta debe distinguirse de la comparación controlada que aísla el efecto espacial.

8. Diagnóstico espacial que conviene calcular sobre el benchmark

Aunque todavía no se ajuste el modelo espacial, sí es conveniente preparar un diagnóstico de dependencia espacial de los residuos del benchmark. Este diagnóstico servirá como línea base.

Sin embargo, primero debe resolverse la geografía exacta de los dominios. La matriz W debe corresponder a las unidades reales de la respuesta. No es correcto construir una matriz de municipios si

algunas respuestas representan áreas metropolitanas y luego interpretar el resultado como si todas las observaciones fueran municipios individuales.

Una vez definida la geografía, se recomienda:

- construir y justificar W;
- calcular Moran global sobre residuos del benchmark;
- inspeccionar el mapa de residuos;
- posteriormente repetir el diagnóstico sobre los residuos del modelo espacial.

La comparación relevante será:

$$I_{\text{residuo, base}} \quad \text{vs.} \quad I_{\text{residuo, espacial}},$$

acompañada de desempeño predictivo y medidas de incertidumbre.

9. Qué cambiará en la predicción cuando exista el modelo espacial

En el benchmark independiente es correcto:

$$\widehat{\theta}_d^{SIN} = x_d^\top \widehat{\beta}.$$

En un modelo espacial, dependiendo de la estructura elegida, el efecto de área de un municipio sin muestra puede tener una predicción condicional basada en efectos de áreas observadas y en la estructura de dependencia.

Por tanto, el futuro predictor espacial debe derivarse de la formulación específica del modelo. No debe suponerse desde ahora que será simplemente el predictor sintético más una corrección ad hoc.

10. Plan de actualización de tablas y figuras

Antes del modelo espacial se recomienda crear o actualizar:

1. tabla de equivalencia entre dominio GEIH y geografía real;
2. tabla de tamaño muestral, PEA y desempleados por dominio;
3. comparación TD oficial versus TD reconstruida;
4. tabla de sensibilidad mensual/trimestral/anual;
5. auditoría de factores de expansión y uniones;
6. tabla de covariables con geografía, período, unidad y denominador;

7. AIC y AICc de M1–M5;
8. estabilidad de coeficientes leave-one-area-out;
9. validación predictiva leave-one-area-out;
10. tabla de soporte/extrapolación de covariables;
11. mapa de residuos del benchmark, una vez definida correctamente la geografía.

Las tablas de predicción municipal actuales pueden conservarse como *resultados del benchmark no espacial*, pero deben quedar claramente identificadas como preliminares y no como estimaciones finales del proyecto.

11. Preguntas que deben quedar respondidas antes de ajustar el modelo espacial

1. ¿Qué geografía exacta representa cada una de las 23 respuestas GEIH?
2. ¿Respuesta, ψ_d y x_d corresponden exactamente al mismo dominio?
3. ¿Cómo se construirán las covariables de un dominio metropolitano?
4. ¿Qué tamaño muestral tiene cada estimación directa de diciembre?
5. ¿Cambian sustancialmente las tasas y ψ_d al usar trimestre o año?
6. ¿El pipeline reproduce resultados oficiales compatibles de GEIH?
7. ¿Cuántos registros presentan problemas de emparejamiento entre módulos?
8. ¿Algún registro de diciembre de 2018 tuvo factor de expansión faltante o igual a cero?
9. ¿Qué criterio único de CV se utilizará?
10. ¿Qué variables se mantendrán congeladas para comparar base y espacial?
11. ¿Cuán estables son esas variables al retirar un dominio?
12. ¿Cuál es el desempeño LOAO del benchmark?
13. ¿Qué variables explican que 76 de 82 municipios se clasifiquen como extrapolaciones?
14. ¿Cuál será la unidad espacial del modelo futuro?
15. ¿Qué matriz W se utilizará y por qué?